

Soutenance de Stage d'Initiation

Département de Mathématiques et Informatique
Ingénierie Informatique : Big Data & Cloud Computing

Conception et déploiement d'un modèle de machine learning pour la détection des fraudes bancaires

Réalisé par :

- FALAG Youssef

Encadrant à l'organisme :

- M. Charhbili Neumann

Membres du jury :

- Mme. Benmoussa Nezha
- Mme. Bensagh Hasnae

Période/Lieu :

Stage effectué du 20/07/2025 au 30/08/2025 Au sein de : VALA

Année universitaire : 2025 – 2026

Plan

▶	Présentation de l'entreprise	01
▶	Problématique et objectifs	02
▶	Exploration des données	03
▶	Modélisation & évaluation des performances	04
▶	Architecture et conception du système	05
▶	Technologies utilisées	06
▶	Démonstration et perspectives	07
▶	Conclusion	08

Présentation de l'entreprise :

Qui est Vala Orange ?

Vala Orange est une entreprise digitale créée en 2020, spécialisée dans le développement web, mobile et les solutions numériques sur mesure.


Contexte du stage ?

- Département : Développement Web
- Période : 20 juillet – 30 août 2025
- Objectif principal : Développer un système de détection automatique des transactions frauduleuses



Problématique

**Problème 1 :
Multiplication des transactions électroniques**



**Problème 3 :
Pertes estimées : plusieurs milliards \$/an**




**Problème 2 :
Augmentation constante des fraudes bancaires**




**Problème 4 :
Méthodes traditionnelles limitées (règles fixes)**

**Comment détecter automatiquement les transactions frauduleuses rares (1,29%)
tout en minimisant les fausses alertes ?**


Objectifs du Projet



Détection des fraudes



Précision et fiabilité




Intégration applicative et déploiement



Exploration des données




Exploration des données – Dataset

- Nombre de transactions : 50 000
- Proportion légitimes/fraudes : 98,71 % vs 1,29 %
- Variables principales : type, montant, soldes, heure, jour



Exploration des données – Dataset

- Transactions les plus frauduleuses : TRANSFER (6-7 %), CASH_OUT (1-2 %)
- Nouvelles features créées : différences de soldes, ratios, transactions à zéro solde, Montants élevés






Modélisation & Evaluation des performances

Modélisation - Approche et Modèles testés


Approche supervisée

Objectif : Classifier chaque transaction en légitime ou frauduleuse


Trois Modèles Testés :



- Modèle linéaire
- Simple et rapide
- Baseline de référence



- Ensemble d'arbres
- Robuste aux outliers
- Gère la non-linéarité



- Gère le déséquilibre
- Régularisation intégrée
- Très performant

Méthodologie d'évaluation & Performance avant équilibrage

1 – Méthodologie d'évaluation :

Métriques utilisées :

- Recall (Fraude)
- Precision (Fraude)
- F1-Score

Validation croisée (Cross-validation)

Optimisation des hyperparamètres (GridSearch)

2 – Performance des modèles avant équilibrage

Modèle	Precision	Recall	F1-score	AUC-ROC
Logistic Regression	0.65	0.58	0.61	0.79
Random Forest	0.78	0.71	0.74	0.88
XGBoost	0.82	0.75	0.78	0.91

Techniques d'équilibrage (SMOTE & Undersampling)



Techniques d'équilibrage :

SMOTE (Oversampling)

- Génère artificiellement des fraudes
- Augmente minorité
- Permet un meilleur apprentissage

Undersampling



- Réduit les transactions légitimes
- Donne un dataset équilibré
- Risque de perte d'information

Performance des modèles (Undersampling)

Modèle	Precision	Recall	F1-score	AUC-ROC
Logistic Regression	0.68	0.83	0.75	0.85
Random Forest	0.93	0.85	0.89	0.94
XGBoost	0.90	0.95	0.92	0.97

Performance des modèles (SMOTE)



Modèle	Precision	Recall	F1-score	AUC-ROC
Logistic Regression	0.71	0.79	0.75	0.87
Random Forest	0.88	0.91	0.89	0.96
XGBoost	0.93	0.94	0.93	0.98




Résultats Finaux & Sélection du Modèle

Comparaison des meilleures configurations pour chaque modèle

Modèle	Technique	Hyperparamètres clés	Recall	F1-score
Logistic Regression	Undersampling	C = 10, max_iter = 1000	0.83	0.75
Random Forest	SMOTE	max_depth = 3, n_estimator = 100	0.91	0.89
XGBoost	SMOTE	max_depth = 6, learning_rate= 0.1, n_estimator = 300	0.94	0.93






Architecture et Conception

Architecture du système :

COMPOSANTS CLÉS :

- Architecture modulaire 3-tiers
- API REST sécurisée (JWT)
- Pipeline ML intégré
- Explicabilité des prédictions (SHAP)
- Conteneurisation Docker
- Traçabilité PostgreSQL



Conception - cas d'utilisation :


Acteurs :

Utilisateur :

- S'authentifier
- Prédire une transaction
- Analyser fichier CSV
- Visualiser résultats

Administrateur :


- Gérer modèles ML
- Gérer les utilisateurs
- Superviser les transactions



Conception - Diagramme de classes :

Entités :

- Utilisateur
- Transaction
- Prediction
- MLModel







Technologies Utilisées

Technologies utilisées :


Développement
WEB



Modélisation
ET
Data Science



Outils de
développement



The background is a solid blue color with several abstract geometric shapes in different shades of blue. There are hexagons of various sizes and orientations, some overlapping. A large, light blue curved shape is on the right side. A white outline of a hexagon is positioned near the top center.

SIMULATION

Limites & Perspectives

Limites

- **Données simulées et non réelles** : Le dataset utilisé est synthétique
- **Performance sensible au déséquilibre** :
Même avec SMOTE, certains cas rares restent difficiles à détecter
- **Modèle non encore monitoré en production** :
Pas de retraining programmé

Perspectives & Améliorations

- **Intégration de données réelles**
- **Mise en place d'un pipeline MLOps**
- **Amélioration du modèle**

The background is a solid blue color. It features several hexagonal shapes: some are solid blue and semi-transparent, while others are white outlines. These shapes are scattered across the frame, with some appearing in the corners and others more centrally. A large, faint, curved blue shape is also visible on the right side of the image.

**Merci pour
votre
Attention**

Soutenance de Stage d'Initiation

Département de Mathématiques et Informatique
Ingénierie Informatique : Big Data & Cloud Computing

Conception et déploiement d'un modèle de machine learning pour la détection des fraudes bancaires

Réalisé par :

- FALAG Youssef

Encadrant à l'organisme :

- M. Charhbili Neumann

Membres du jury :

- Mme. Benmoussa Nezha
- Mme. Bensagh Hasnae

Période/Lieu :

Stage effectué du 20/07/2025 au 30/08/2025 Au sein de : VALA

Année universitaire : 2025 – 2026